

Qualité et au delà du relationnel

BUT2, CM1, 2022-2023

Gilles Nachouki

- 1- Etude de la qualité dans les bases de données relationnelles : concevoir un schéma normalisé et connaître la qualité du schéma avec ses avantages et ses inconvénients
- 2- Aller au delà du modèle relationnel : les bases de données NoSQL.

Au sommaire:

- Bases de données relationnelles :
 - ① Modèle de données
 - ② Normalisation et qualité
- Bases de données non relationnelles :
 - ① Modèles de données
 - ② Introduction à MongoDB

Dépendances fonctionnelles

Soit la relation $R(A,B,C)$, l'attribut B est dit fonctionnellement dépendant de l'attribut A si étant donné 2 n-uplets :

$\langle a1, b1, c1 \rangle$ et $\langle a2, b2, c2 \rangle$ $a1 = a2 \rightarrow b1 = b2$

On la note $A \rightarrow B$

Propriétés des dépendances fonctionnelles

Soit une relation $R(A,B,C,D)$

- ① réflexivité : $A \rightarrow A$
- ② augmentation : si $A \rightarrow B$ alors $A, C \rightarrow B$
- ③ transitivité : si $A \rightarrow B$ et $B \rightarrow C$ alors $A \rightarrow C$
- ④ pseudo-transitivité : si $A \rightarrow B$ et $B, C \rightarrow D$ alors $A, C \rightarrow D$
- ⑤ union : si $A \rightarrow B$ et $A \rightarrow C$ alors $A \rightarrow B, C$
- ⑥ décomposition : si $A \rightarrow B, C$ alors $A \rightarrow B$ et $A \rightarrow C$.

Typologie des dépendances fonctionnelles

- dépendance triviale : une dépendance $X \rightarrow Y$ est triviale si $Y \subset X$,
- dépendance simple : une dépendance $X \rightarrow Y$ est dite simple si sa partie droite ne comporte qu'un seul attribut,
- dépendance élémentaire (complète): une dépendance $X \rightarrow Y$ est élémentaire si pour tout $X' \subset X$, la dépendance fonctionnelle $X' \rightarrow Y$ n'est pas vérifiée. En d'autres termes, Y ne dépend pas fonctionnellement d'une partie de X ,
- dépendance directe : une dépendance $X \rightarrow Y$ est directe si Y ne dépend pas de X par transitivité (cad il existe Z tel que $X \rightarrow Z$ et $Z \rightarrow Y$).

Formes Normales

Les trois premières formes normales:

- 1NF: une relation est dite en 1NF si tout attribut a un domaine qui contient uniquement des valeurs atomique,
- 2NF : une relation est dite en 2NF si et seulement si elle est en 1NF et que tout attribut n'appartenant pas à la clé de la relation R ne dépend pas d'une partie de la clé de R (dépendances élémentaires).

Formes Normales

- 3NF: une relation est dite en 3NF si elle est en 2NF et si tout attribut n'appartenant pas à la clé de R ne dépend pas transitivement de la clé (dépendances directes).
Remarque : la 3NF ne traite pas de façon correcte le cas d'une relation qui a 2 clés candidates ou plus telles que : (1) les deux clés candidates sont composées et (2) elles se chevauchent
- 3NFBC : une relation est en 3NFBC (Forme Normale de Boyce Codd) si elle est en troisième forme normale et si les seules sources de dépendances sont des clés de R

Formes Normales

On considère la relation R suivante :

A	B	C
1	2	4
2	2	4
3	2	4
3	5	6
5	5	7

- L'ensemble $DF = \{ AB \rightarrow C, C \rightarrow B \}$
- La clé primaire primaire de la relation R est AB. AC est une clé candidate.
- $\{A,B\} \cap \{A,C\} \neq \phi$.
- Cette relation est en 3NF mais pas en 3NFBC.

- Fermeture transitive de F (F^t): obtenue par application de la propriété de transitivité sur l'ensemble F de dépendances fonctionnelles.

Exemple : $F = \{A \rightarrow B, B \rightarrow C\}$

$F^t = \{A \rightarrow B, B \rightarrow C, A \rightarrow C\}$

- La fermeture d'un ensemble F de DFs (F^+) est obtenue en appliquant toutes les propriétés de dépendances fonctionnelles.

Exemple :

$$F = \{A \rightarrow B, B \rightarrow A\}$$

$$F^+ = \{A \rightarrow B, B \rightarrow A, A \rightarrow A, B \rightarrow B, AB \rightarrow A, AB \rightarrow B, AB \rightarrow AB\}$$

La fermeture d'un ensemble X d'attributs de R dans F (X_F^+) constitue l'ensemble des attributs de R qui peuvent être obtenus à partir de X en appliquant les propriétés de dépendances fonctionnelles

Un ensemble minimal de dépendances de F permettant de générer toutes les dépendances de F^+ :

- 1 $F^+(F_{min}) = F^+(F)$,
- 2 il n'existe pas $F' / F' \subset F_{min}$ et $F^+(F') = F^+(F_{min})$

Algorithmes

Dans cette section, on étudie quelques algorithmes indispensables pour concevoir une base de données normalisée en 3NF ou 3NFBC

- A1- Recherche de la fermeture d'un ensemble d'attributs X de R dans F
- A2- Recherche de la couverture minimale de F (F_{min})
- A3- Recherche d'un schéma en 3NF (algorithme de synthèse)
- A4- Recherche d'un schéma en 3NFBC (algorithme de décomposition)

Algorithme 1 : fermeture d'un ensemble X d'attributs de R dans F

$X^+ := X$

Répéter

Aux := X^+

Pour chaque DF $Y \rightarrow Z$ de F faire

si Y est inclus dans X^+ alors $X^+ := X^+ \cup Z$

Jusqu'à Aux := X^+ ou $X^+ = R$

Exemple :

Soit $R = (A, B, C, D, E)$ et

$F = \{A \rightarrow B, B \rightarrow C, ABE \rightarrow D, A \rightarrow C\}$.

La fermeture de l'ensemble $X = \{B, E\}$ dans F , $(BE)_F^+ = \{B, E, C\}$

Algorithme 2 : calcul de la couverture minimale (F_{min}) d'un ensemble de Dfs

Les étapes :

- Rendre les DF simples : $X \rightarrow A$ où X est un attribut simple ou composé, A est un attribut simple,
- Eliminer les attributs superflus: Soit $(X \rightarrow A) \in F$, on dit qu'un attribut $B \in X$ est superflu si on a: $((F - \{X \rightarrow A\}) \cup \{X - \{B\} \rightarrow A\})^+ = F^+$,
- Eliminer les DF redondantes : $X \rightarrow A$ est redondante ssi $(F - (X \rightarrow A))^+ = F^+$.

Exemple : couverture minimale

soit $R = (A,B,C,D,E)$ et $F = \{A \rightarrow B, B \rightarrow C, ABE \rightarrow D, A \rightarrow C\}$

- Première étape : On vérifie facilement que toutes les df sont simples dans F .
- Deuxième étape : éliminer les attributs superflus : on considère la dépendance suivante : $ABE \rightarrow D$. Est-ce que l'attribut A est superflu dans cette dépendance? On cherche la fermeture de l'ensemble d'attributs $X = \{B,E\}$ dans F . Est-ce que $D \in X_F^+$? Si oui alors l'attribut A dans $ABE \rightarrow D$ est superflu. $X_F^+ = \{B,E, C\}$ et $D \notin X_F^+$ donc A n'est pas superflu.
- Est-ce que l'attribut B est superflu? la réponse est oui
- Dernière étape : éliminer les dfs redondantes. Est-ce que la df $A \rightarrow C$ est redondante ? On cherche si $C \in A_F^+$ dans l'ensemble $F - \{A \rightarrow C\}$

Algorithme 3 de synthèse

On part d'une relation et d'un ensemble F de dépendances fonctionnelles. Le principe de cet algorithme est le suivant :

- on remplace F par une couverture minimale F_{min} ,
- on regroupe les dfs ayant même membre gauche X ($X \rightarrow A$).
Pour chaque membre gauche X , on définit un schéma de relation contenant tous les attributs intervenant dans ces dfs.
- si aucun des schémas définis à l'étape 2 ne contient de clé R , on ajoute un schéma de relation muni d'une clé de R .

Qualité de schéma

- Chaque schéma issu de cette décomposition est en 3NF;
- Cette décomposition est sans perte de données et sans perte de dépendances fonctionnelles.

Exemple : Algorithme de synthèse

Soit $R = (A, B, C, D, E)$ et $F = \{A \rightarrow B, A \rightarrow D, B \rightarrow C, E \rightarrow D\}$

- On part de la couverture minimale de F . On cherche la clé de R : AE .
- On regroupe les DF qui ont même membre gauche :
 $R_1(A, B, D) \ F_1 = \{A \rightarrow B, A \rightarrow D\}$
 $R_2(B, C) \ F_2 = \{B \rightarrow C\}$
 $R_3(E, D) \ F_3 = \{E \rightarrow D\}$
- On ajoute $R_4(A, E) \ F = \{\}$
Cette décomposition est SPI et SPD.

Algorithme 4 de décomposition

On part d'une relation R et d'un ensemble F de dépendances fonctionnelles. Le principe de cet algorithme est le suivant :

- on remplace F par une couverture minimale F_{min} ,
- trouver dans R une dépendance non triviale $X \rightarrow Y$ telle que X ne contienne pas une clé de R
- remplacer R par $R_1(X \cup Y, F_1)$ et $R_2(U - Y, F_2)$ où F_1 et F_2 sont deux ensembles de dépendances fonctionnelles obtenues à partir de F ,
- pour tout $R_i(X_i, F_i)$ et $R_j(X_j, F_j)$ tels que $X_i \subseteq X_j$ supprimer R_i .

Qualité de schéma

- Chaque schéma issue de cette décomposition est en 3NFBC;
- Cette décomposition est sans perte de données mais elle ne garantie pas de retrouver toutes les dépendances fonctionnelles.

Exemple : Algorithme de décomposition

Soit $R = (A, B, C, D, E)$ et $F = \{A \rightarrow B, A \rightarrow D, B \rightarrow C, E \rightarrow D\}$

- On part de la couverture minimale de F. On cherche la clé de R AE.
- On décompose selon la DF suivante : $A \rightarrow B$. On obtient : $R_1(A, B)$, $F_1 = \{A \rightarrow B\}$ et $R_2(A, C, D, E)$ et $F_2 = \{A \rightarrow D, E \rightarrow D\}$. La clé de R_2 est ACE. On décompose selon la DF $A \rightarrow D$. On obtient : $R_{21}(A, D)$, $F_{21} = \{A \rightarrow D\}$ et $R_{22}(A, C, E)$, $F_{22} = \{\}$. Cette décomposition est sans perte de données mais avec perte de DF.

Théorème de Heath

- Soit la relation $R(X,Y,Z)$ et la dépendance fonctionnelle suivante : $X \rightarrow Y$ alors R est décomposable sans perte d'information (SPI) en deux relations $R_1(X,Y)$ et $R_2(X,Z)$. R égale à la jointure de sa projection sur $\{X,Y\}$ et $\{X,Z\}$,
- Toute relation a au moins une décomposition en troisième forme normale qui est SPI et sans perte de dépendances fonctionnelles (SPD)

Théorème d'ULLMAN

- la décomposition d'une relation est dite sans perte d'information ssi: $X = X1 \cup X2$ et $X1 \cap X2 \rightarrow X1 - X2$ ou $X2 - X1$,
- la décomposition est dite sans perte de dépendances ssi $F^+ = (F1 \cup F2)^+$